Aprendizagem de Máquina na Educação: Modelagem Preditiva e Análise de Importância de Variáveis Socioeconômicas nas Notas do ENEM

Andrey H. de Abreu Carneiro
Departamento de Computação
Universidade Federal do Ceará
andreyhenrique@alu.ufc.br

Paulo J. dos Santos Jr.
Departamento de Computação
Universidade Federal do Ceará
paulo.santos@alu.ufc.br

Clara A. de Aguiar
Departamento de Computação
Universidade Federal do Ceará
clara.aguiar@alu.ufc.br

Resumo

O presente artigo analisou a capacidade de prever o desempenho acadêmico de estudantes baseando-se em suas informações socioeconômicas, demográficas e educacionais. O trabalho utilizou microdados do ENEM 2018, o exame de maior relevância para o ingresso no ensino superior no Brasil. O estudo estabeleceu uma comparação entre modelos de regressão linear e técnicas de comitês de árvores (ensembles), como Random Forest, LightGBM e CatBoost, na tarefa de estimar a nota média dos candidatos.

1 Introdução

A Mineração de Dados Educacionais (MDE) é uma ferramenta consolidada de extrema importância e tem um grande poder informativo, auxiliando governos na tomada de decisões e na elaboração de políticas públicas eficientes na área da educação [Vahat et al. [2016]]. Esse campo utiliza técnicas estatísticas e computacionais que fazem o reconhecimento de padrões que não são imediatamente visualizáveis, servindo de fundação para análises e modelagem de módulos complexos que possibilitam compreender os fatores mais relevantes no processo de aprendizado — por exemplo, durante a prática de jogos eletrônicos [Segal et al. [2014]]. Com base nesses microdados, torna-se possível estimar proficiências e mapear atributos relevantes, como condições socioeconômicas, formação docente, ambiente escolar e infraestrutura.

No Brasil, uma rica fonte de dados na área da educação é oriunda de exames nacionais, como o Exame Nacional de Desempenho de Estudantes (ENADE) e o Exame Nacional do Ensino Médio (ENEM), que coletam diversos dados sobre os candidatos. O ENEM é uma política pública criada em 1998 pelo governo federal brasileiro com o objetivo de avaliar a qualidade da educação nas escolas de ensino médio e prover uma padronização do conhecimento, objetivo que se manteve por uma década. A partir de 2009, o exame passou a ser uma porta de entrada para vagas em instituições de ensino superior, como universidades públicas, através do Sistema de Seleção Unificada (SiSU), ou para bolsas de estudo em instituições privadas pelo Programa Universidade para Todos (ProUni). Em 2018, o exame contou com mais de 5 milhões de inscritos. Todo aluno que se inscreve para fazer a prova precisa preencher um questionário socioeconômico e, anualmente, datasets são disponibilizados de forma gratuita pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Neste trabalho, realizou-se um estudo sobre a capacidade de prever a nota de um aluno utilizando dados socioeconômicos como variáveis (features) em modelos de aprendizagem de máquina. Para isso, foi necessário selecionar modelos de regressão que capturassem adequadamente as relações entre os fatores socioeconômicos e que também suportassem grandes volumes de dados. Árvores de decisão são modelos capazes de desempenhar essa tarefa com eficiência [Hastie et al. [2005]]. Além disso, modelos baseados em árvores podem prover um entendimento claro das regras construídas para a regressão, devido à sua alta explicabilidade e transparência. Modelos assim são chamados de whitebox, enquanto aqueles que seu funcionamento interno não é explícito são chamados de blackbox.

Contudo, um modelo de Árvore de Decisão, quando utilizado de forma isolada, é frequentemente classificado como um algoritmo preditivo "fraco"(weak learner). Uma solução eficaz para superar essa limitação é a combinação de diversos modelos para criar um comitê (ensemble) com alto poder preditivo [Woźniak et al. [2014]]. Nesse contexto, este trabalho estabeleceu uma comparação entre três abordagens: a Regressão Linear, utilizada como linha de base (baseline); a Random Forest, fundamentada na técnica de bagging; e o Gradient Boosting, representado pelas implementações de alto desempenho LightGBM [Ke et al. [2017]] e CatBoost [Prokhorenkova et al. [2018]].

O desenvolvimento deste trabalho foi estruturado em duas etapas principais: o pré-processamento com otimização de hiperparâmetros e a avaliação diagnóstica dos modelos. Na primeira etapa, realizou-se a limpeza e codificação das variáveis (Label Encoding para modelos de árvore e One-Hot Encoding para modelos lineares), seguida de uma busca pelos melhores parâmetros utilizando Grid Search e Randomized Search, tendo como função objetivo a minimização do Root Mean Squared Error (RMSE). Na segunda etapa, a validação dos modelos foi conduzida através da partição dos dados em conjuntos de treino e teste, utilizando um amplo espectro de métricas de desempenho: R^2 para medir a variância explicada, MAE e MedAE para avaliar o erro médio e a robustez a outliers, e sMAPE para o erro relativo.

Adicionalmente, este estudo foi além da capacidade preditiva ao incorporar uma camada de interpretabilidade via SHAP (SHapley Additive exPlanations). Através do uso de TreeExplainer e LinearExplainer, foi possível decompor as predições e identificar quais indicadores socioeconômicos — como renda familiar (Q006) e escolaridade dos pais (Q001 e Q002) — exercem maior impacto na nota final dos candidatos. A comparação entre o desempenho dos regressores e a linha de base (MAE da média) permitiu quantificar o ganho informativo proporcionado pelos algoritmos de aprendizagem de máquina, sendo possível prever a nota do aluno com um MAE de 58.30, enquanto o MAE da média é de 76.60, evidenciando como os padrões ocultos nos microdados do INEP podem auxiliar na compreensão das desigualdades educacionais no Brasil.

2 Fundamentação Teórica

Breve descrição técnica do problema escolhido, descrição dos dados (atributos, saídas, etc) e revisão de trabalhos similares.

2.1 Descrição técnica do problema

O problema abordado neste trabalho consiste na predição da nota média do Exame Nacional do Ensino Médio (ENEM) 2018 a partir de fatores socioeconômicos, demográficos e educacionais dos participantes. Do ponto de vista computacional, trata-se de um problema de regressão supervisionada, no qual o objetivo é estimar um valor numérico contínuo (nota média do ENEM) com base em um conjunto de variáveis explicativas. Essa abordagem permite analisar a influência desses fatores no desempenho acadêmico e apoiar estudos sobre desigualdades educacionais.

2.2 Descrição dos dados

O conjunto de dados utilizado neste trabalho corresponde aos microdados do Exame Nacional do Ensino Médio (ENEM), que representam o menor nível de desagregação das informações coletadas por meio do exame. Os dados foram obtidos a partir do portal de dados abertos do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira [INEP, 2019] e referem-se ao ano de 2018, totalizando 5.513.733 registros e 78 variáveis.

Os dados passaram por um processo de limpeza e pré-processamento, resultando em um conjunto final composto por **289.762** amostras, selecionadas a partir do total de **1.448.812** registros disponíveis após a filtragem inicial. Essa redução foi adotada visando a **eficiência computacional e a velocidade** nos ciclos de treinamento e otimização dos modelos. Ressalta-se que o desempenho obtido com essa amostra apresentou resultados equivalentes aos observados na base completa, mantendo a representatividade necessária para o estudo.

O conjunto final é composto por **40 variáveis**, sendo 10 atributos que descrevem características do participante, 2 referentes à instituição de ensino, 27 correspondentes ao perfil socioeconômico e 1 variável alvo, definida como a nota média do ENEM.

Para uma análise mais aprofundada do problema, foi realizada uma análise exploratória dos dados com o objetivo de identificar os principais fatores associados ao desempenho médio no ENEM. Entre as variáveis analisadas, destaca-se a renda familiar do participante, cuja relação com a nota média é apresentada na Figura 1. Observa-se que faixas de renda mais elevadas, representadas pelas categorias de A (menor renda) a Q (maior renda), estão associadas a maiores notas médias no exame.

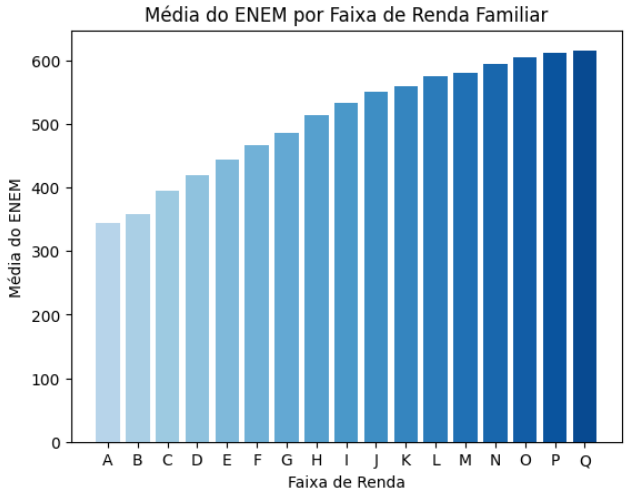

Figura 1: Média do ENEM por renda familiar

A Figura 2 ilustra a relação entre o tipo de instituição de ensino frequentada (municipal, estadual, federal ou privada) e a nota média, indicando que escolas federais e privadas apresentam, em média, melhor desempenho.

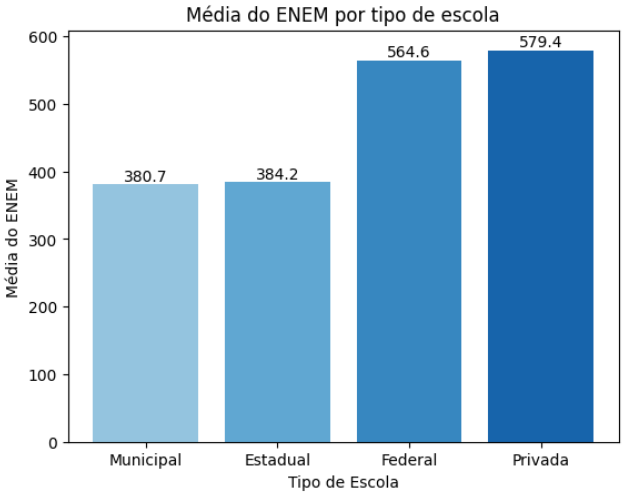

Figura 2: Média do ENEM por tipo de escola

Adicionalmente, a Figura 3 apresenta a relação entre a quantidade de computadores disponíveis no domicílio do participante e sua nota média, indicando que o acesso a recursos tecnológicos está associado a melhores resultados no exame.

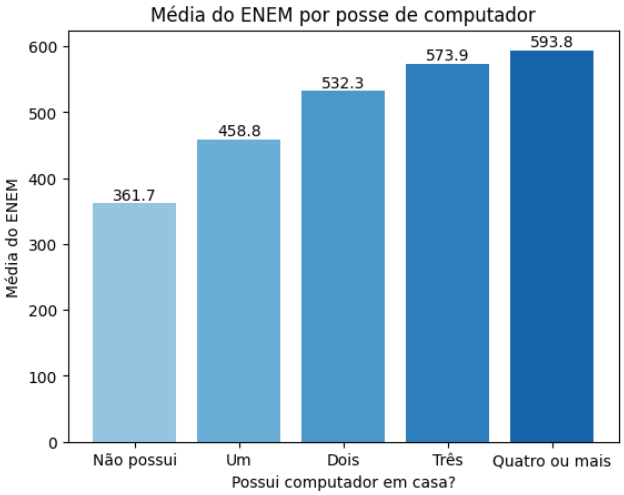

Figura 3: Média do ENEM por posse de computador

2.3 Atributos de entrada

As informações referentes aos participantes incluem dados como faixa etária, sexo, estado civil, cor/raça, nacionalidade e características relacionadas ao ensino médio, tais como situação de conclusão, ano de conclusão, tipo de escola frequentada (pública, privada ou no exterior) e indicação de participação como treineiro.

As informações sobre as escolas abrangem o tipo de instituição (federal, estadual, municipal ou privada) e a sua localização geográfica (urbana ou rural).

Além disso, foram coletados dados relacionados à situação socioeconômica dos participantes, conforme apresentado na 1. Esses dados compreendem 27 questões que abordam aspectos do núcleo familiar, escolaridade, infraestrutura domiciliar, bens de consumo e acesso à tecnologia.

Tabela 1: Questionário Socioeconômico - ENEM 2018

ID	Descrição da Pergunta
Núcleo Familiar e Escolaridade	
Q001	Escolaridade do pai (ou homem responsável).
Q002	Escolaridade da mãe (ou mulher responsável).
Q003	Grupo de ocupação do pai (ou responsável).
Q004	Grupo de ocupação da mãe (ou responsável).
Q005	Quantidade de pessoas que moram na residência.
Q006	Renda mensal total da família.
Infraestrutura e Bens de Consumo	
Q007	Possui empregado(a) doméstico(a).
Q008	Possui banheiro.
Q009	Possui quartos para dormir.
Q010	Possui carro.
Q011	Possui motocicleta.
Q012	Possui geladeira.
Q013	Possui freezer independente.
Q014	Possui máquina de lavar roupa.
Q015	Possui máquina de secar roupa.
Q016	Possui forno micro-ondas.
Q017	Possui máquina de lavar louça.
Q018	Possui aspirador de pó.
Q019	Possui televisão a cores.
Q020	Possui aparelho de DVD.
Q021	Possui TV por assinatura.
Tecnologia e Estudos	
Q022	Possui telefone celular.
Q023	Possui telefone fixo.
Q024	Possui computador.
Q025	Possui acesso à Internet.
Q026	Já concluiu ou está cursando o Ensino Médio.
Q027	Tipo de escola que frequentou o Ensino Médio.

2.4 Trabalhos relacionados

Na literatura, observa-se um número crescente de estudos com aprendizado de máquina dedicados à investigação do desempenho de estudantes em exames em larga escala a partir de variáveis socioeconômicas. A seguir serão discutidos os principais trabalhos relacionados.

[Stearns et al., 2017] utilizaram dados socioeconômicos do ENEM 2014 para prever notas de Matemática, comparando os algoritmos AdaBoost e Gradient Boosting com otimização via PSO. O Gradient Boosting obteve o melhor desempenho (MAE 65.9), confirmando a forte influência de indicadores sociais e geográficos no resultado do exame.

[Alves, 2018] aplicou técnicas de mineração de dados no ENEM 2016 para classificar o desempenho na prova de redação em um recorte regional (Santa Catarina), comparando os algoritmos J48 e Naive Bayes. O modelo baseado em Naive Bayes alcançou a melhor acurácia (61,7%), evidenciando que a renda familiar e o número de moradores na residência figuram como as variáveis de maior impacto na predição da nota.

[Santos, 2020] utilizou os microdados do ENEM 2018 para estimar as notas de Matemática e Redação em âmbito nacional, comparando algoritmos como Redes Neurais, Random Forest e Regressão Linear. Os resultados indicaram que a Regressão Linear obteve o melhor desempenho para Matemática (MAE entre 60 e 80), e para a Redação (MAE entre 125 e 150), apontando o tipo de escola, renda familiar e posse de computador como atributos de alta relevância preditiva.

[Souza et al., 2017] estenderam a análise para o ensino superior, utilizando Árvores de Decisão e Regressão Logística para prever o conceito de cursos no ENADE. Ao validar o modelo via validação cruzada (10-fold), os autores obtiveram uma estatística KS (Kolmogorov-Smirnov) média de 24,2%.

Os resultados demonstraram que a unidade federativa e a renda familiar são preditores determinantes, evidenciando que a influência das variáveis socioeconômicas transcende o exame de admissão e impacta o desempenho durante a graduação.

3 Metodologia

Esta seção detalha a abordagem técnica adotada para o desenvolvimento dos modelos preditivos de desempenho no ENEM 2018, cobrindo desde o processamento da base de dados bruta até as estratégias de validação e interpretabilidade dos algoritmos.

3.1 Processamento e Tratamento de Dados

Devido ao grande volume de dados dos microdados do ENEM (5.513.733), a etapa inicial de ingestão e processamento utilizou a biblioteca Polars, uma ferramenta de manipulação de dataframes otimizada para alta performance, em conjunto com a biblioteca Pandas.

O fluxo de pré-processamento consistiu nas seguintes etapas:

- **Seleção de Atributos:** Foram isoladas as variáveis socioeconômicas (questões Q001 a Q027 do questionário), dados demográficos (idade, sexo, cor/raça) e escolares (tipo de escola, dependência administrativa), além das notas das provas objetivas e redação.
- **Engenharia de Atributos:** Criação da variável alvo `nota_media`, calculada a partir da média aritmética das notas das cinco competências (Linguagens, Ciências Humanas, Ciências da Natureza, Matemática e Redação).
- **Tratamento de Valores Ausentes:** Remoção de registros com notas inexistentes ou nulas, garantindo que o modelo fosse treinado apenas com dados de candidatos que realizaram todas as provas.
- **Codificação de Variáveis:** As variáveis categóricas do questionário socioeconômico foram transformadas em representações numéricas utilizando a técnica de Label Encoding (via LabelEncoder do Scikit-Learn), adequada para modelos baseados em árvores de decisão que conseguem interpretar relações ordinais.

3.2 Modelos de Aprendizagem de Máquina

Para a tarefa de regressão (predição da nota média), foram selecionados algoritmos com diferentes abordagens para permitir uma análise comparativa de desempenho:

- **Regressão Linear:** Utilizada como modelo base (baseline) para estabelecer um patamar mínimo de desempenho e verificar a linearidade das relações entre as variáveis socioeconômicas e a nota.
- **Random Forest Regressor:** Um método de ensemble que combina múltiplas árvores de decisão para reduzir o overfitting e capturar relações não-lineares complexas.
- **CatBoost Regressor e LightGBM:** Algoritmos de Gradient Boosting de última geração, escolhidos por sua eficiência no tratamento de variáveis categóricas e alta velocidade de treinamento em grandes conjuntos de dados.

3.3 Análise de Resultados e Métricas de Avaliação

A avaliação dos modelos foi realizada mediante a divisão dos dados em conjuntos de treino e teste. As seguintes métricas foram adotadas para mensurar a qualidade das predições:

- **Raiz do Erro Quadrático Médio (RMSE):** Mede a raiz quadrada do erro quadrático médio, mantendo a unidade da variável alvo (pontos). Penaliza fortemente erros grandes, sendo especialmente útil para identificar se o modelo apresenta falhas graves em algumas previsões específicas.
- **Erro Médio Absoluto (MAE):** Mede a média da diferença absoluta entre os valores preditos e os reais. É uma métrica de fácil interpretação, pois representa o erro médio cometido pelo modelo na mesma unidade da nota (pontos).

- **Erro Mediano Absoluto (MedAE):** Calcula a mediana dos erros absolutos, sendo menos sensível a outliers do que o MAE. Representa o erro típico cometido pela maioria das previsões, oferecendo uma visão mais robusta do desempenho do modelo.
- **Coeficiente de Determinação (R^2):** Indica a proporção da variância da nota média que é explicada pelas variáveis socioeconômicas e demográficas utilizadas no modelo. Valores mais próximos de 1 indicam melhor ajuste do modelo aos dados.
- **sMAPE (Symmetric Mean Absolute Percentage Error):** Mede o erro percentual médio de forma simétrica entre valores reais e preditos. Essa métrica permite avaliar o erro relativo do modelo, sendo útil para comparar desempenho em diferentes faixas de nota.
- **Erro Máximo Absoluto (Max Error):** Representa o maior erro absoluto cometido pelo modelo em uma única previsão. Essa métrica evidencia o pior caso observado, auxiliando na identificação de falhas extremas do modelo.
- **Percentis do Erro Absoluto (P50, P75, P90, P95):** Descrevem a distribuição dos erros absolutos. O percentil 50 (mediana) indica o erro típico, enquanto percentis mais altos mostram o comportamento do modelo nos casos mais difíceis, revelando a concentração de erros elevados.
- **Proporção de Erros Graves**: Mede a porcentagem de previsões cujo erro absoluto ultrapassa um limiar crítico (por exemplo, 150 pontos). Essa métrica é importante para avaliar o risco do modelo cometer erros considerados inaceitáveis no contexto educacional.
- **Acurácia por Tolerância ($\pm$50 e $\pm$100 pontos):** Indica a porcentagem de previsões cuja diferença entre o valor real e o predito está dentro de uma margem aceitável. Essa métrica fornece uma interpretação prática do desempenho do modelo, alinhada a critérios de erro tolerável.

3.4 Interpretabilidade do Modelo

A interpretabilidade dos modelos foi assegurada através do método SHAP (SHapley Additive exPlanations), contornando a dificuldade de explicar as decisões de algoritmos complexos de árvore. Apoiada em princípios matemáticos da teoria dos jogos, a ferramenta possibilita:

- **Interpretação Global:** Identificar quais variáveis socioeconômicas (ex: renda, escolaridade da mãe, acesso a computador) têm maior impacto geral na predição da nota.
- **Interpretação Local:** Explicar, para um candidato específico, como cada uma de suas características contribuiu para aumentar ou diminuir sua nota predita em relação à média.

4 Experimentos e Resultados

Esta seção apresenta os resultados dos experimentos computacionais realizados com a base de dados **ENEM 2018** previamente pré-processada, contendo **289 762** amostras e **40 variáveis socioeconômicas**. O objetivo dos experimentos foi avaliar a eficácia de modelos de regressão na predição da nota média dos candidatos utilizando informações socioeconômicas, do participante e da instituição de ensino.

Todos os modelos foram treinados com hiperparâmetros otimizados e avaliados em um conjunto de teste separado, correspondente a **20%** dos dados. O desempenho foi avaliado por meio de métricas padrão de regressão.

4.1 Otimização de Hiperparâmetros

A otimização de hiperparâmetros foi realizada com o objetivo de aprimorar o desempenho preditivo dos modelos de regressão. Para o CatBoost Regressor, que apresentou os melhores resultados gerais, foi empregada uma estratégia de busca aleatória combinada com validação cruzada. O critério de otimização adotado foi a minimização da Raiz do Erro Quadrático Médio (RMSE).

A melhor configuração de hiperparâmetros encontrada para o CatBoost Regressor é apresentada na Tabela 2. Essa configuração resultou em um RMSE de **77.68** nos folds de validação, indicando um bom equilíbrio entre complexidade do modelo e capacidade de generalização.

Tabela 2: Hiperparâmetros otimizados do CatBoost Regressor.

Hiperparâmetro	**Valor**
Número de iterações	1000
Profundidade da árvore	8
Taxa de aprendizado	0.03
Regularização L_2 (λ)	7

A configuração selecionada reflete um ensemble relativamente profundo, aliado a uma taxa de aprendizado moderada, permitindo ao modelo capturar relações não lineares complexas, ao mesmo tempo em que mitiga o sobreajuste por meio da regularização L_2. O uso de um grande número de iterações de boosting combinado com uma taxa de aprendizado reduzida contribui para uma convergência estável e melhor generalização.

4.2 Desempenho do Modelo

Após a otimização de hiperparâmetros, o **CatBoost Regressor** apresentou o melhor desempenho geral, superando significativamente modelos de base, como a Regressão Linear, bem como outras abordagens baseadas em árvores.

A Tabela 3 resume o desempenho do CatBoost Regressor no conjunto de teste.

Tabela 3: Desempenho do CatBoost Regressor no conjunto de teste.

Métrica	**Valor**
R^2	0.3806
RMSE	77.63
MAE	58.30
MedAE	45.46
sMAPE (%)	11.79

Os resultados indicam que o modelo explica aproximadamente **38%** da variância da variável alvo, confirmando que os dados socioeconômicos contêm informações relevantes para a predição do desempenho no ENEM. O erro médio absoluto de **58.3 pontos** representa uma melhoria substancial em relação a um baseline ingênuo que prediz a média global das notas, o que resultaria em um coeficiente R^2 próximo de zero.

Além disso, o valor inferior do erro absoluto mediano em comparação ao MAE sugere que a maioria das predições apresenta erros moderados, enquanto um pequeno número de casos extremos eleva o erro médio.

4.3 Análise de Resíduos do Modelo CatBoost

Para validar a qualidade do ajuste do **CatBoost Regressor** e verificar a existência de padrões sistemáticos de erro, realizou-se a análise da distribuição dos resíduos ($e = y - \hat{y}$). A Figura 4 apresenta a frequência desses erros para o conjunto de teste.

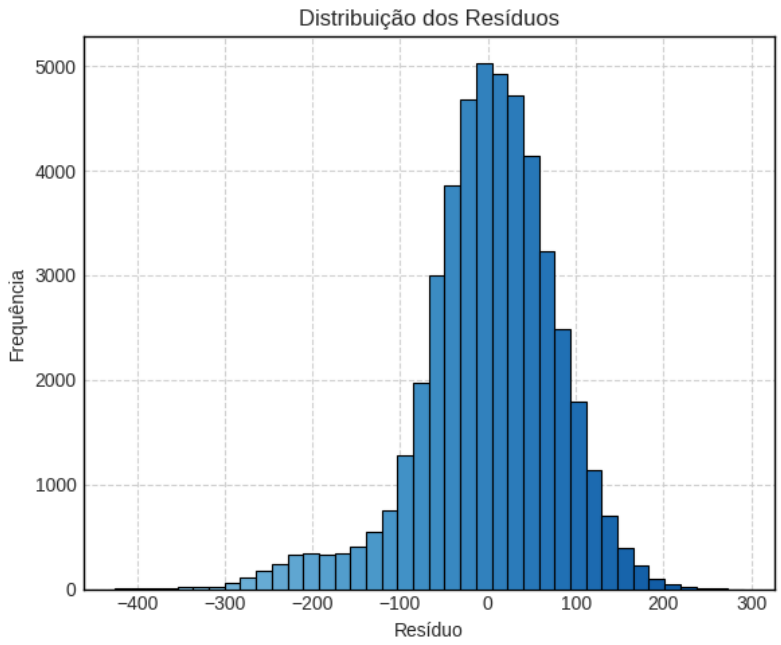

Figura 4: Distribuição dos resíduos para o CatBoost Regressor.

A análise do histograma revela características importantes sobre a precisão do modelo:

- **Centralidade e Viés:** A distribuição apresenta um pico proeminente centrado em zero, com mais de 5.000 amostras concentradas na faixa central de erro. Isso indica que o modelo é, em média, não enviesado, acertando a tendência central das notas dos candidatos.
- **Concentração do Erro:** A vasta maioria dos resíduos situa-se entre -100 e 100 pontos, o que corrobora os resultados de MAE (58,30) e MedAE (45,46) apresentados anteriormente. A alta densidade em torno do zero demonstra que o modelo possui boa capacidade preditiva para a maioria dos perfis de candidatos.
- **Simetria:** Observa-se uma distribuição aproximadamente simétrica, sugerindo que o modelo não possui uma tendência preferencial de subestimar ou superestimar as notas de forma generalizada.
- **Comportamento das Caudas:** Embora a distribuição seja bem comportada no centro, nota-se a presença de caudas leves que se estendem até ± 300 pontos. Tais valores extremos de resíduo ocorrem em uma frequência muito baixa e estão associados a casos onde as variáveis socioeconômicas disponíveis não são suficientes para explicar desempenhos acadêmicos excepcionais ou quedas bruscas de rendimento individual.

Esta análise gráfica confirma a robustez estatística do CatBoost Regressor, demonstrando que os erros de predição comportam-se de forma aleatória e concentrada, o que é desejável para modelos de regressão em larga escala.

4.4 Distribuição e Qualidade do Erro

A análise da distribuição do erro absoluto revela que:

- 50% das predições apresentam erro inferior a 45.5 pontos;
- 75% apresentam erro inferior a 79.2 pontos;
- 90% apresentam erro inferior a 123.1 pontos;
- apenas 5% excedem 161.1 pontos.

Adicionalmente, apenas **6.03%** das amostras apresentam erro severo (erro absoluto superior a 150 pontos), indicando que falhas preditivas de grande magnitude são relativamente raras.

4.5 Erro Médio por Faixa de Nota

A Figura 5 apresenta o erro absoluto médio para diferentes faixas de nota real.

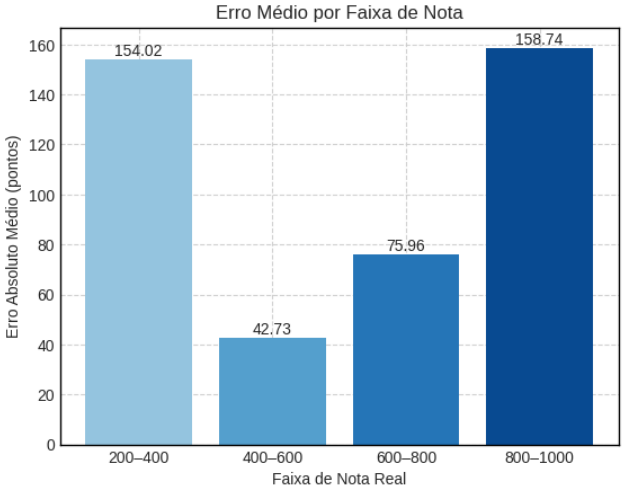

Figura 5: Erro absoluto médio por faixa de nota real para o CatBoost Regressor.

O menor erro médio ocorre na faixa de notas **400–600**, com aproximadamente **43 pontos**, enquanto as faixas extremas (**200–400** e **800–1000**) apresentam erros significativamente maiores, superiores a **150 pontos**. Esse comportamento sugere maior dificuldade do modelo em lidar com candidatos nos extremos da distribuição de notas, possivelmente devido à maior variabilidade ou menor representatividade desses grupos nos dados.

4.6 Acurácia sob Diferentes Tolerâncias de Erro

A Figura 6 apresenta a acurácia das predições sob diferentes tolerâncias de erro.

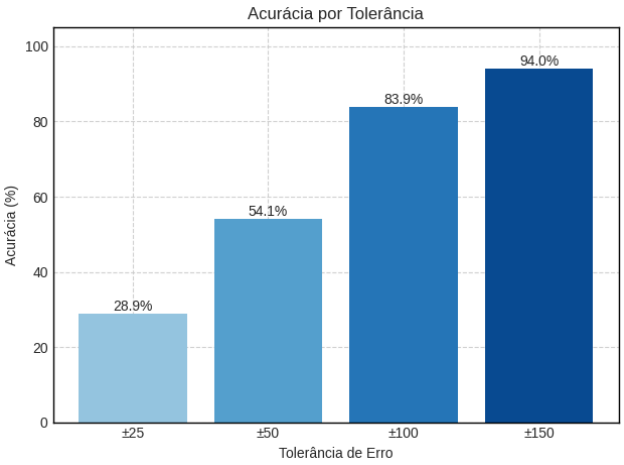

Figura 6: Acurácia da predição sob diferentes tolerâncias de erro para o CatBoost Regressor.

Os resultados mostram que:

- 28.9% das predições encontram-se dentro de ± 25 pontos;
- 54.1% estão dentro de ± 50 pontos;

- 83.9% estão dentro de ± 100 pontos;
- 94.0% apresentam erro inferior a ± 150 pontos.

Esses resultados demonstram a robustez do modelo, especialmente para níveis de tolerância compatíveis com análises educacionais e socioeconômicas em larga escala.

4.7 Análise de Erros Extremos

Apesar do bom desempenho médio, foram observados erros de predição extremos. Dois casos representativos foram analisados.

No primeiro caso, o modelo **subestimou severamente** um candidato com nota real de **711.8**, prevendo apenas **421.1**, o que resultou em um erro de **290.7 pontos**. No segundo caso, o modelo **superestimou** a nota de um candidato com valor real de **246.9**, prevendo **672.4**, gerando um erro de **425.5 pontos**.

A inspeção dos atributos socioeconômicos nesses casos sugere que combinações atípicas de variáveis, como tipo de escola, renda familiar e escolaridade dos responsáveis, podem induzir o modelo a extrapolações incorretas, evidenciando limitações na aplicação das predições em nível individual.

4.8 Interpretabilidade e Importância das Variáveis (SHAP)

Para compreender como cada variável socioeconômica contribui para a predição das notas, utilizou-se o *SHAP (SHapley Additive exPlanations)*, uma abordagem baseada na teoria dos jogos que atribui a cada característica um valor de importância para o resultado final do modelo. A Figura 7 apresenta o *summary plot*, que ordena as variáveis de cima para baixo de acordo com sua magnitude de impacto médio.

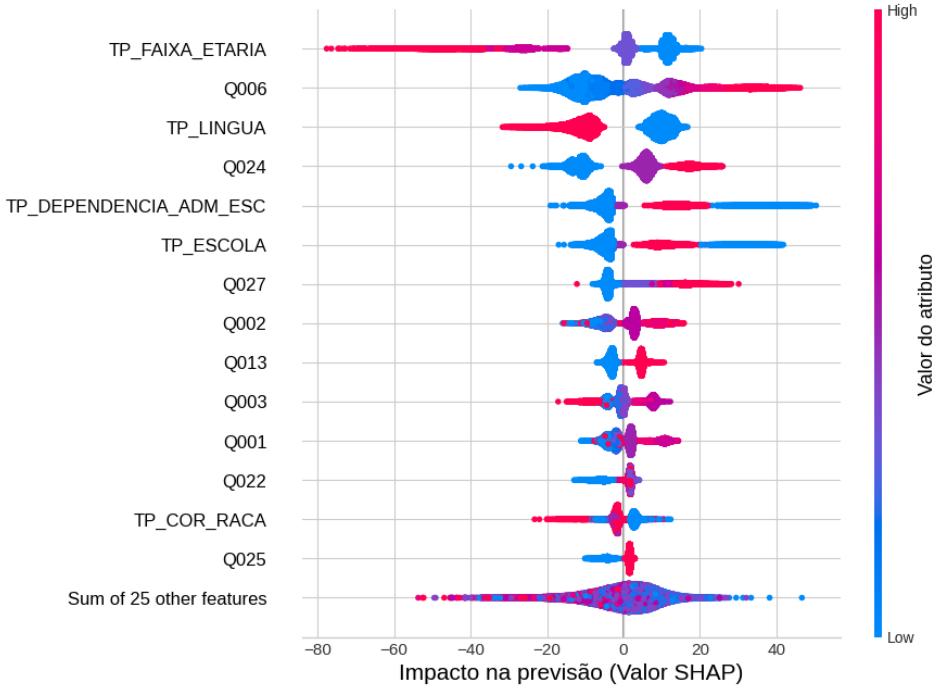

Figura 7: Distribuição dos valores SHAP para as principais variáveis do modelo. Cores avermelhadas indicam valores altos da variável, enquanto azul representa valores baixos.

A análise do gráfico revela padrões fundamentais sobre a influência do perfil socioeconômico no desempenho dos candidatos:

- **Renda Mensal Familiar (Q006):** Esta variável apresenta um dos maiores impactos positivos. Observa-se que valores altos da variável (em vermelho) estão concentrados à direita

do eixo zero, indicando que quanto maior a renda familiar, maior o incremento positivo na nota prevista.

- **Faixa Etária (TP_FAIXA_ETARIA):** Curiosamente, esta variável apresentou o maior impacto em termos de magnitude absoluta, porém inversamente proporcional. Os pontos vermelhos (candidatos com idade mais elevada) estão situados à esquerda, sugerindo que o aumento da idade tende a reduzir a nota predita, possivelmente devido ao maior tempo de afastamento da educação formal.
- **Infraestrutura e Tecnologia (Q024 e Q013):** A posse de bens como computadores (Q024) e o acesso a recursos domésticos (Q013) mostram uma correlação clara com o aumento da nota. A presença de computadores em casa (pontos vermelhos à direita) é um divisor significativo no desempenho acadêmico.
- **Tipo de Escola e Dependência Administrativa (TP_ESCOLA e TP_DEPENDENCIA_ADM_ESC):** Candidatos provenientes de escolas privadas (valores altos nestas variáveis) apresentam SHAP values positivos. Isso evidencia o impacto estrutural da rede de ensino no resultado final do aluno.
- **Escolaridade Materna (Q002) e Idioma (TP_LINGUA):** O nível de instrução da mãe (Q002) demonstra que um maior capital cultural familiar eleva a predição da nota. Já em relação à língua estrangeira, a opção pelo Inglês (valores baixos em TP_LINGUA, representados em azul à direita) tende a estar associada a notas mais altas em comparação ao Espanhol.

Esses resultados corroboram a literatura educacional brasileira, destacando que fatores de renda e capital cultural são os principais preditores do sucesso no exame, reforçando o papel do modelo como uma ferramenta capaz de capturar desigualdades estruturais.

4.9 Discussão

De forma geral, o CatBoost Regressor demonstrou forte desempenho preditivo ao utilizar dados socioeconômicos para estimar as notas do ENEM, superando abordagens de base. No entanto, o aumento do erro nas faixas extremas da distribuição de notas e a presença de erros raros, porém severos, indicam oportunidades para trabalhos futuros, incluindo balanceamento dos dados, incorporação de variáveis adicionais e estratégias de modelagem híbridas.

5 Conclusão

O presente trabalho cumpriu o objetivo de investigar a predição da nota média do ENEM 2018 utilizando algoritmos de Aprendizado de Máquina aplicados a variáveis socioeconômicas. A análise demonstrou que fatores externos à escola possuem um peso determinante no desempenho acadêmico, permitindo que modelos computacionais expliquem uma parcela significativa da variação das notas.

Os resultados experimentais revelaram que o modelo CatBoost Regressor foi o mais eficaz para esta tarefa, apresentando um erro médio absoluto de 58,30 pontos e um coeficiente de determinação (R^2) de 0,3806. Esses números comprovam que, mesmo sem informações sobre o histórico escolar ou pedagógico direto, o perfil socioeconômico do candidato oferece sinais robustos para a estimativa de seu desempenho. A análise de interpretabilidade reforçou que a renda familiar e o acesso a recursos tecnológicos são os principais divisores de desempenho no cenário educacional brasileiro.

Contudo, observou-se que a precisão do modelo diminui nos extremos da distribuição de notas, indicando que desempenhos excepcionais ou quedas bruscas de rendimento individual dependem de fatores que transcendem os dados socioeconômicos disponíveis. Para investigações futuras, sugere-se o uso de técnicas de balanceamento de dados e a inclusão de variáveis contextuais sobre as escolas para reduzir os erros nas faixas de notas mais altas e baixas.

Em suma, este estudo consolida a ideia de que o aprendizado de máquina pode ser uma ferramenta poderosa para diagnosticar desigualdades estruturais. Espera-se que estas descobertas possam subsidiar debates sobre políticas públicas de equidade, voltadas para a democratização do acesso ao ensino superior no Brasil.

Contribuição dos autores: O pré-processamento e a curadoria dos dados foram realizados por A.H.A.C. e C.A.A. A implementação e o treinamento dos modelos foram desenvolvidos em conjunto por P.J.S.J., C.A.A. e A.H.A.C., enquanto a avaliação dos resultados e análise de métricas ficaram sob responsabilidade de P.J.S.J. e A.H.A.C. A redação das seções do artigo foi distribuída entre os autores: resumo e introdução (Seção 1) por P.J.S.J., fundamentação teórica e metodologia (Seções 2 e 3) por C.A.A., e experimentos e conclusão (Seções 4 e 5) por A.H.A.C. A revisão textual, consolidação do manuscrito e aprovação da versão final foram realizadas por todos os autores.

Tabela 4: Resumo comparativo de desempenho dos modelos de regressão

Modelo	R^2	**RMSE**	**MAE**	**sMAPE (%)**	**Acc $\pm$50 (%)**	**Acc $\pm$100 (%)**
CatBoostRegressor	0.3806	77.63	58.30	11.79	54.15	83.92
LightGBM	0.3785	78.05	58.69	11.86	53.71	83.70
RandomForestRegressor	0.3754	78.25	58.85	11.90	53.63	83.67
LinearRegression	0.3434	80.22	60.43	12.20	52.54	82.56

Referências

Rafael Damiani Alves. Predição do desempenho da redação do enem utilizando técnicas de mineração de dados, 2018. URL https://repositorio.ufsc.br/handle/123456789/187760.

Trevor Hastie, Robert Tibshirani, Jerome Friedman, and James Franklin. The elements of statistical learning: data mining, inference and prediction. *The Mathematical Intelligencer*, 27(2):83–85, 2005. doi: 10.1007/BF02985802. URL https://doi.org/10.1007/BF02985802.

INEP. Microdados do exame nacional do ensino médio 2018, 2019. URL https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem. Acesso em: 07 jan. 2026.

Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 3146–3154, 2017. URL https://arxiv.org/abs/1706.09516.

Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, pages 6638–6648, 2018. URL https://proceedings.neurips.cc/paper/2018/hash/144c159c30545c116407f546193e977-Abstract.html.

Manoela Cassia dos Santos. Desenvolvimento de modelos para estimar principais características socioeconômicas para as notas de redação e matemática para enem 2018, 2020. URL http://www.repositorio.ufal.br/jspui/handle/123456789/9205.

Avi Segal, Galit Katz, Ya'akov Gal, and Guy Shani. Predicting student performance and learning strategies in online games. In *Proceedings of the 7th International Conference on Educational Data Mining (EDM)*, pages 68–75, 2014. URL https://educationaldatamining.org/EDM2014/uploads/procs2014/long%20papers/68_EDM-2014-Full.pdf.

Hugo Vieira Lucena de Souza, Davi Hirafuji Neiva, Rafael Pereira Cavalcanti, Rodrigo Lins Rodrigues, Alex Sandro Gomes, and Paulo Jorge Leitão Adeodato. Uma análise preditiva de desempenho dos cursos no enade com base no perfil socioeconômico e desempenho no enem dos alunos. In *Anais dos Workshops do VI Congresso Brasileiro de Informática na Educação (WCBIE 2017)*, pages 684–693, Porto Alegre, RS, Brasil, 2017. SBC. doi: 10.5753/cbie.wcbie.2017.684. URL https://br-ie.org/pub/index.php/wcbie/article/view/7454.

Bernardo Stearns, Flavio Rangel, Fabrício Firmino, Fabio Rangel, and Jonice Oliveira. Prevendo desempenho dos candidatos do enem através de dados socioeconômicos. In *Anais do XXXVI Concurso de Trabalhos de Iniciação Científica da SBC*, pages 2522–2530, Porto Alegre, RS, Brasil, 2017. SBC. URL https://sol.sbc.org.br/index.php/ctic/article/view/3244.

Arnon Vahat, Robert Schaffer, Ahmad Tarmazi, and Hendrik Drachsler. Advances in learning analytics and educational data mining. In Charles Lang, George Siemens, Alyson Wise, and Dragan Gašević, editors, *Learning Analytics: From Research to Practice*, pages 1–15. Routledge, 2016. URL `https://www.researchgate.net/publication/298412528_Advances_in_learning_analytics_and_educational_data_mining`.

Michał Woźniak, Manuel Graña, and Emilio Corchado. A survey of multiple classifier systems as hybrid systems. *Information Fusion*, 16:3–17, 2014. ISSN 1566-2535. doi: 10.1016/j.inffus.2013.04.006.